Ανταγωνιστική μάθηση

Αυτο-οργάνωση: βιολογικά πρότυπα

- Τοπικότητα λειτουργιών
- Γεωμετρική διάταξη νευρώνων

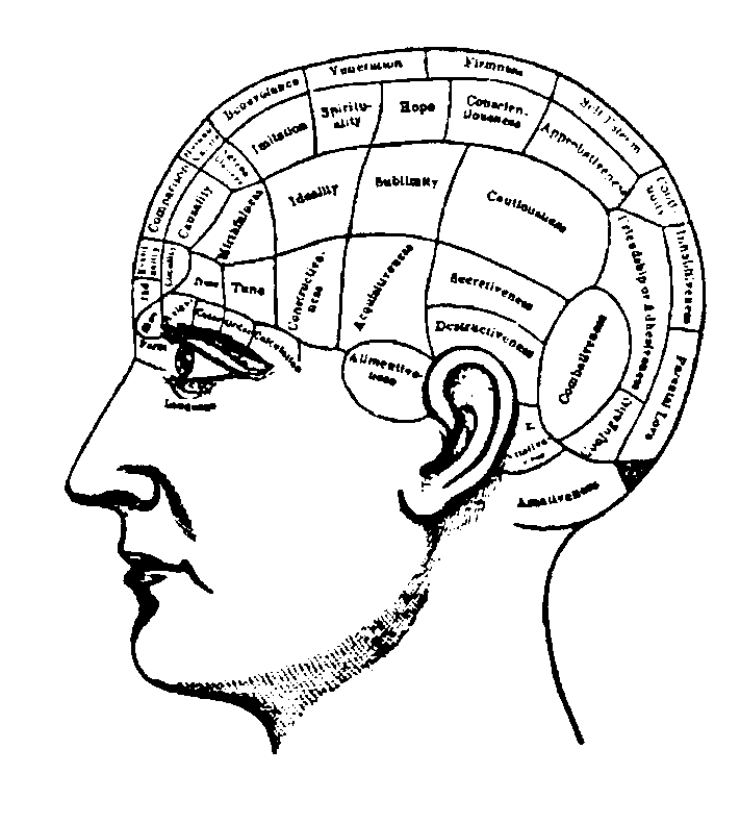

Μάθηση χωρίς επίβλεψη (Unsupervised learning)

- Μη επιγεγραμμένα (unlabelled) δεδομένα
- *Ομαδοποίηση* (clustering)

  Όμοιες είσοδοι πρέπει να ανήκουν στην ίδια ομάδα.

  Οι ομάδες προσδιορίζονται από το δίκτυο βάσει συσχετίσεων των δεδομένων εισόδου.
- *Αυτο-οργάνωση*
- Κωδικοποίηση και συμπίεση δεδομένων $\Rightarrow$

  Κβαντισμός διανύσματος (vector quantization)
- *Χάρτες χαρακτηριστικών* (feature maps)
- Ανάλυση δεδομένων – data mining

Δίκτυα ανταγωνιστικής μάθησης

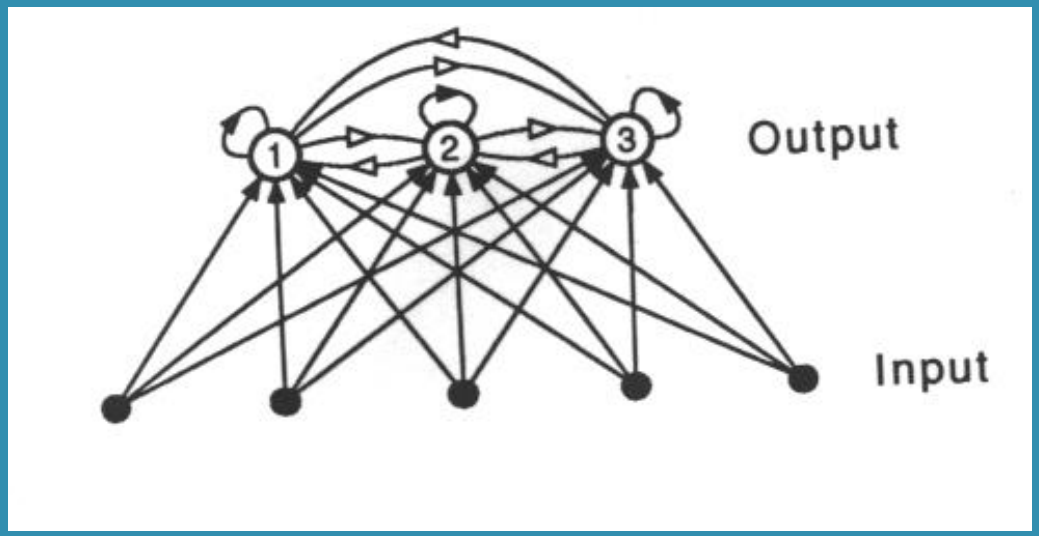

N: αριθμός προτύπων εισόδου
n: διάσταση εισόδου
M: αριθμός νευρώνων εξόδου (ομάδων)

Επίπεδο εισόδου: Πρόσθια τροφοδότηση
Επίπεδο εξόδου: Ανταγωνιστικό επίπεδο

Δίκτυα ανταγωνιστικής μάθησης

ΑΝΤΑΓΩΝΙΣΤΙΚΟΙ ΝΕΥΡΩΝΕΣ

"Winner-take-all" units (WTA)

"Grandmother" cells

Εγκάρσια ανάδραση (lateral feedback)

- Εγκάρσια διέγερση (κοντινοί νευρώνες)
- Εγκάρσια ανάσχεση (μακρινοί νευρώνες)

Βιολογικό πρότυπο: σταδιακή μετάβαση

"Mexican hat"

"On-center/
Off-surround"
cells

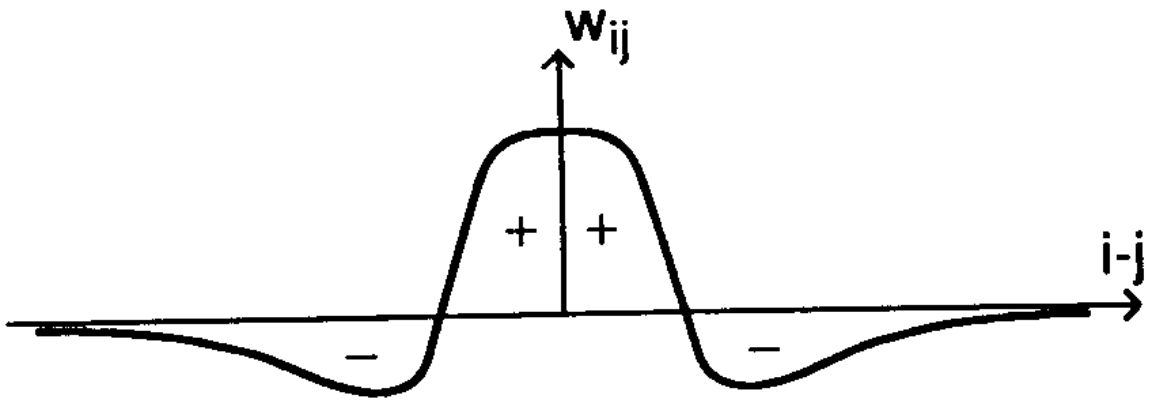

Απλή ανταγωνιστική μάθηση

Φάση ανταγωνισμού

Νικητής

$\Rightarrow$ μέγιστη σταθμισμένη είσοδος
(εσωτερικό γινόμενο)

$$\max \; s_i = \sum_j w_{ij} x_j = \vec{w}_i \vec{x}$$

$\Rightarrow$ ελάχιστη ευκλείδεια απόσταση

$$\min \; d_i = \left\| \vec{w}_i - \vec{x} \right\|$$

Ισοδύναμα αν τα βάρη
είναι κανονικοποιημένα, π.χ. $\left\| \vec{w}_i \right\| = 1, \quad \forall i$

Maxnet: υλοποίηση εγκάρσιας ανάδρασης (R. Lippman, 1987)

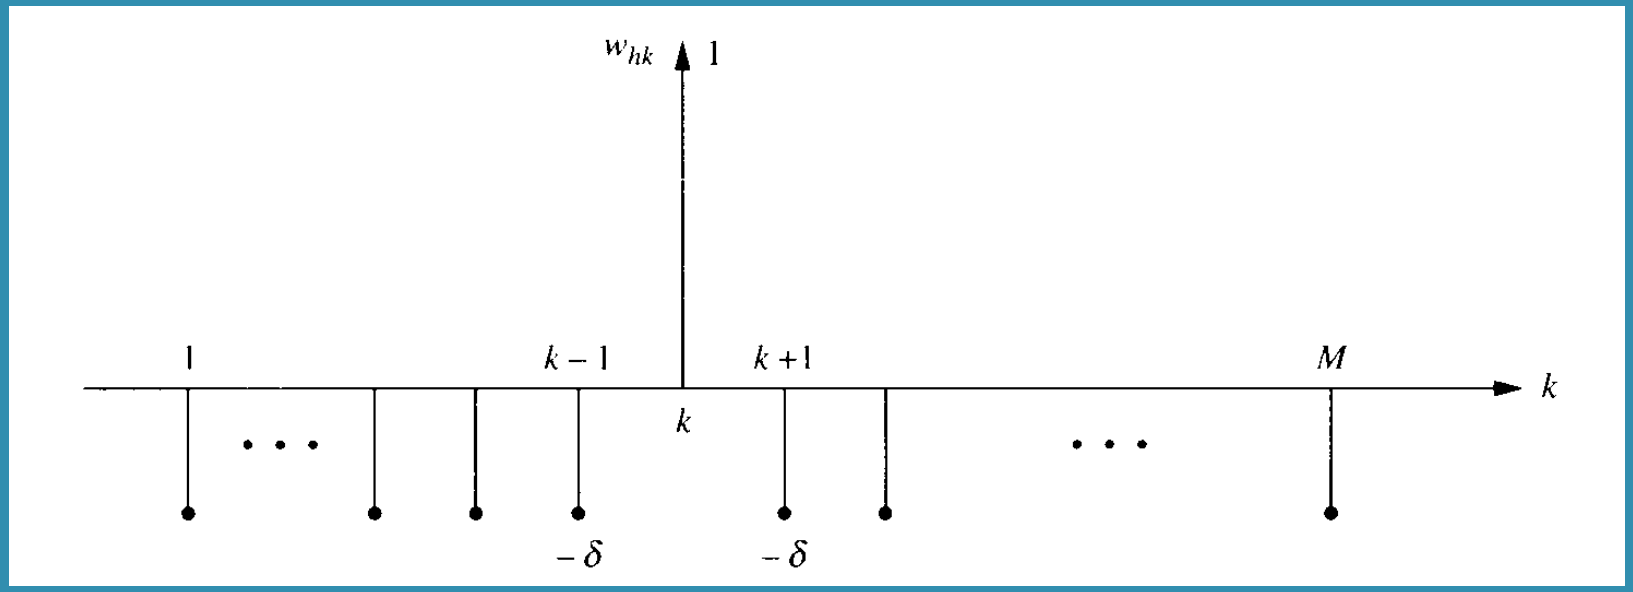

$$w_{hk} = \begin{cases} 1, & h = k \\ -\delta, & h \neq k, \delta < 1/(M-1) \end{cases} \qquad 1 \leq h, k \leq M$$

Maxnet: λειτουργία ανταγωνιστικού επιπέδου

Αρχικές είσοδοι
(αφαιρούνται στη συνέχεια)

$$s_i = \sum_j w_{ij} x_j$$

Επαναληπτικός υπολογισμός εξόδων
(σιγμοειδής f)

$$y_i(0) = f(s_i)$$

$$y_i(\tau+1) = f\left(y_i(\tau) - \delta \sum_{k \neq i} y_k(\tau) \right)$$

Εγγυημένη σύγκλιση ανταγωνισμού

Δίκτυο δύο επιπέδων:

Πρόσθια τροφοδότηση +
επαναληπτική λειτουργία (Maxnet)
= Hamming Net

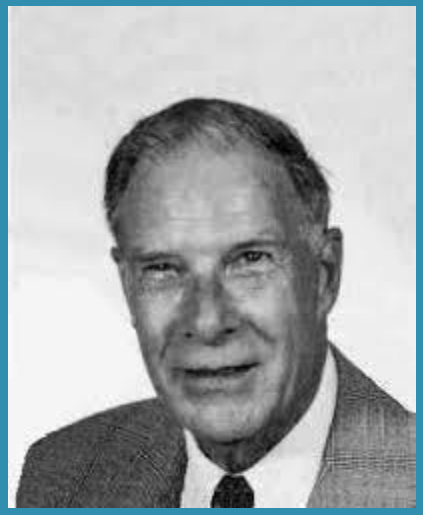

Richard W. Hamming
1915-1998

(Turing Award, 1968)

Απλή ανταγωνιστική μάθηση

Φάση ανταμοιβής

Βασικός κανόνας

$$\vec{w}_i^{(t+1)} = \vec{w}_i^{(t)} + \eta(t)\left[\vec{x} - \vec{w}_i^{(t)}\right]$$

$$0 \le \eta(t) \le 1$$

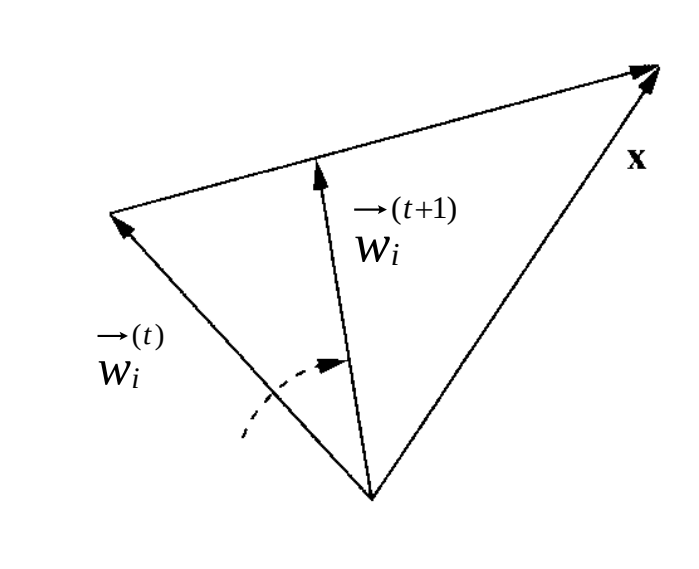

Πιθανή κανονικοποίηση βαρών

Φθίνων συντελεστής μάθησης

Απλή ανταγωνιστική μάθηση

Ομαδοποίηση:

Σύγκλιση στα κέντρα βάρους

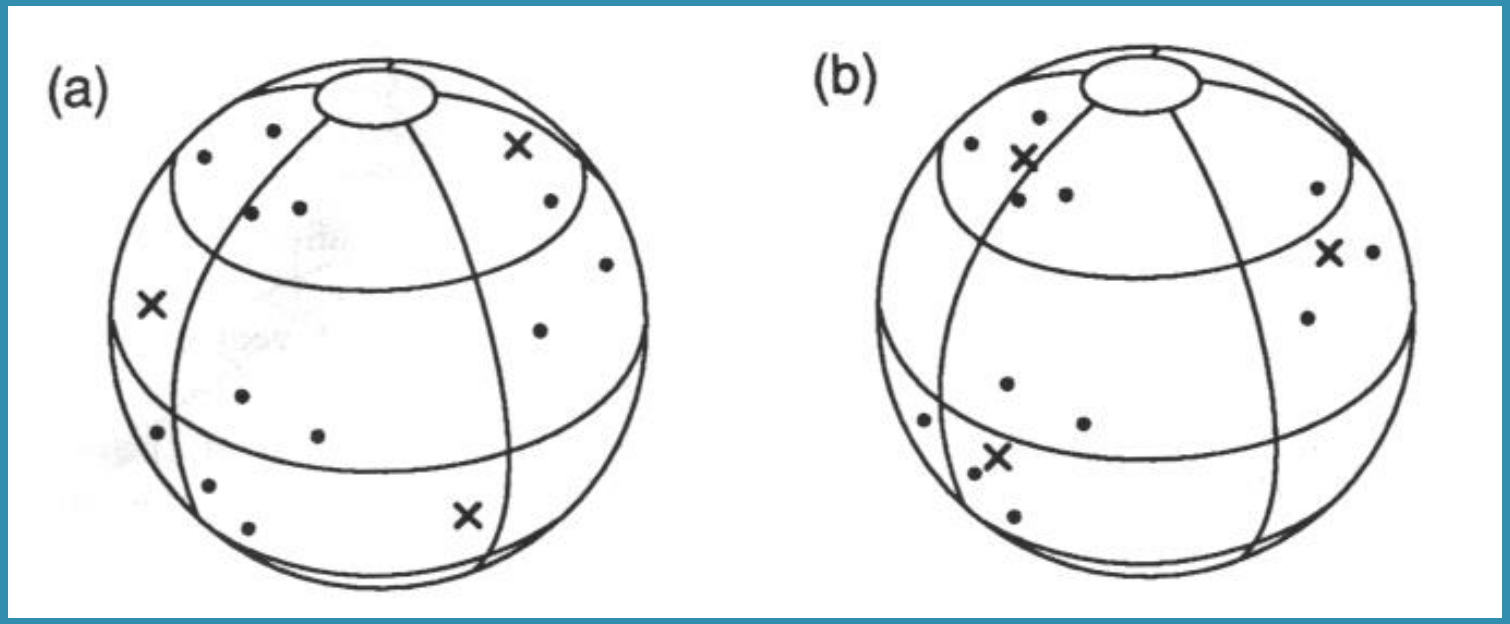

Το πρόβλημα των “νεκρών” κόμβων

Απλή ανταγωνιστική μάθηση

Ελαχιστοποίηση συνάρτησης κόστους

$$E(\vec{w}) = \tfrac{1}{2}\sum_k \sum_i M(i,k)\left\|\vec{x}^{\,i} - \vec{w}_k\right\|^2$$

$$= \tfrac{1}{2}\sum_k \sum_i \sum_j M(i,k)\left(x_j^i - w_{kj}\right)^2$$

$$M(i,k) = \begin{cases} 1 & \text{αν } k \text{ νικητής με είσοδο } \vec{x}^{\,i} \\ 0 & \text{αλλιώς} \end{cases}$$

Συνάρτηση συμμετοχής ομάδας

Κάθοδος κλίσης: τοπικά ελάχιστα

$$\Delta\vec{w}_k = -\eta\frac{\partial E}{\partial \vec{w}_k} = \eta\sum_i M(i,k)\left(\vec{x}^{\,i} - \vec{w}_k\right)$$

Προσέγγιση αυξητικής μεταβολής

Διανυσματικός κβαντισμός (vector quantization - VQ)

- *M* κατηγορίες διανυσμάτων (codebook)
- Εύρεση συνόλου πρωτότυπων διανυσμάτων (prototype vectors)

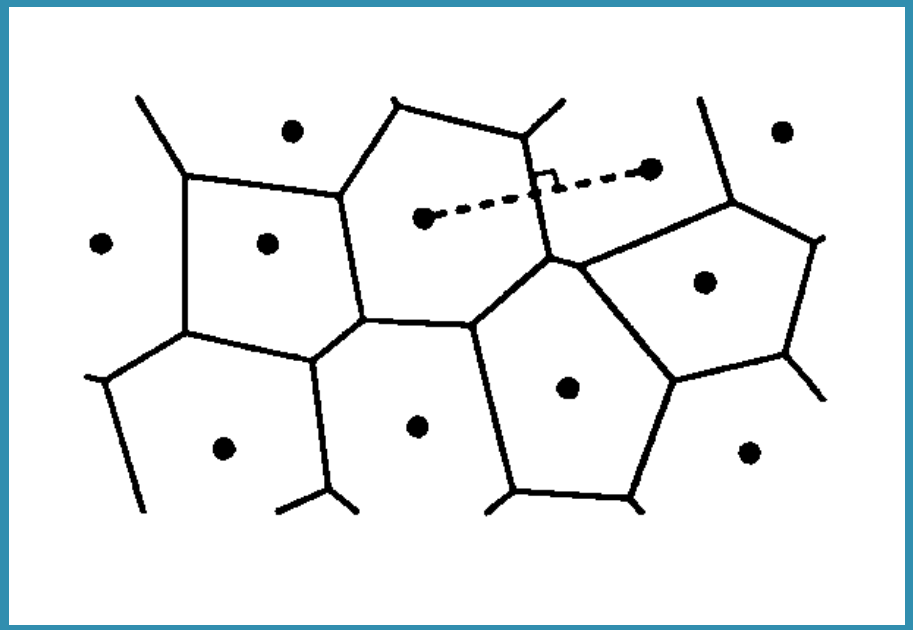

Πλησιέστερος γείτονας (nearest-neighbor)

$\Downarrow$

Διάγραμμα Voronoi (ψηφιδοθέτηση Dirichlet)

Ο αλγόριθμος *k*-μέσων (*k*-means)

- Σταθερός (προκαθορισμένος) αριθμός ομάδων
- Σημειακή ομαδοποίηση (point clustering)
- Παραμετρική ομαδοποίηση
  - Εύρεση συμπαγών ομάδων (νεφών)
  - Κάθε ομάδα αντιπροσωπεύεται από ένα σημείο.
- Άκαμπτη ομαδοποίηση (hard clustering)
  - Αντιστοίχιση καθενός προτύπου σε μια ομάδα

Ο αλγόριθμος k-μέσων

Σε κάθε βήμα :

- Ταξινόμηση καθενός προτύπου στην ομάδα Ω_k με τη μικρότερη απόσταση

$$d(\vec{x}^{\,i}, \vec{w}_k) = \min_j d(\vec{x}^{\,i}, \vec{w}_j)$$

- Υπολογισμός των νέων κέντρων των ομάδων

$$\vec{w}_j^{\,(t+1)} = \frac{1}{N_j^{(t)}} \sum_{\vec{x}^{\,i} \in \Omega_j^{(t)}} \vec{x}^{\,i}$$

N_j: αριθμός προτύπων στην ομάδα Ω_j

Συνολική ενημέρωση (batch update) σε κάθε βήμα

$\Rightarrow$ Κάθοδος κλίσης

Ασαφής ομαδοποίηση (Fuzzy clustering)

- Εύκαμπτη ομαδοποίηση (soft clustering)

  - Κάθε πρότυπο μπορεί να ανήκει σε περισσότερες από μία ομάδες.

  - Βαθμός συμμετοχής (membership degree) $u_{ij} \in [0,1]$ του προτύπου i στην ομάδα j

$$\sum_{j=1}^{M} u_{ij} = 1$$

- Δυνατότητα μετάβασης σε άκαμπτη ομαδοποίηση

  Παρέχει περισσότερη πληροφορία (κέντρα ομάδων και βαθμός συμμετοχής).

Ασαφής αλγόριθμος *k*-μέσων (Fuzzy *k*-means)

Σε κάθε βήμα :

- Υπολογισμός βαθμών συμμετοχής

$$u_{ij}^{(t)} = \frac{1}{\sum_{k=1}^{M} \frac{d(\vec{x}^{\,i}, \vec{w}_j^{\,(t)})}{d(\vec{x}^{\,i}, \vec{w}_k^{\,(t)})}}$$

- Υπολογισμός των νέων κέντρων των ομάδων

$$\vec{w}_j^{\,(t+1)} = \frac{\sum_{i=1}^{N} \left(u_{ij}^{(t)}\right)^q \vec{x}^{\,i}}{\sum_{i=1}^{N} \left(u_{ij}^{(t)}\right)^q}$$

q>1

τυπική τιμή q=2

Διανυσματικός κβαντισμός: Μη επιβλεπόμενη μάθηση

Απλή ανταγωνιστική μάθηση

Νευρωνική (σειριακή) διατύπωση του αλγορίθμου *k*-μέσων

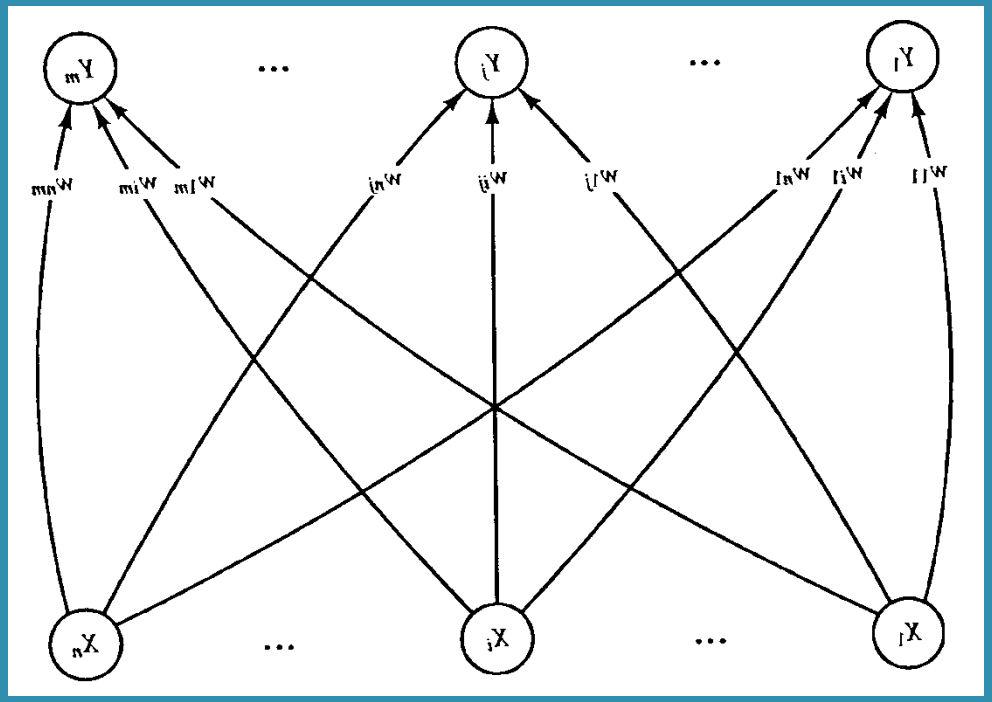

Αριθμός εξόδων = αριθμός ομάδων

Ενημέρωση βαρών του νικητή μόνο

Διανυσματικός κβαντισμός: Επιβλεπόμενη μάθηση

Ο αλγόριθμος LVQ

(Learning Vector Quantization)

(Teuvo Kohonen, 1989)

- Επιγεγραμμένα (labelled) εκπαιδευτικά πρότυπα (συμμετοχή σε κατηγορίες)
- Ανάθεση ενός ή περισσότερων πρωτότυπων διανυσμάτων ανά κατηγορία (αρχικοποίηση βαρών με εκπαιδευτικά πρότυπα)

Ο αλγόριθμος LVQ

Ανταμοιβή

Ενημέρωση των βαρών μόνο του νικητή ανάλογα με την κατηγορία του

$$\Delta\vec{w}_k = \begin{cases} \eta\left(\vec{x} - \vec{w}_k\right) \\ -\eta\left(\vec{x} - \vec{w}_k\right) \end{cases}$$

Σωστή κατηγορία νικητή

Λανθασμένη κατηγορία νικητή (απώθηση)

Βελτιωμένες εκδόσεις: LVQ1 (conscience), LVQ2

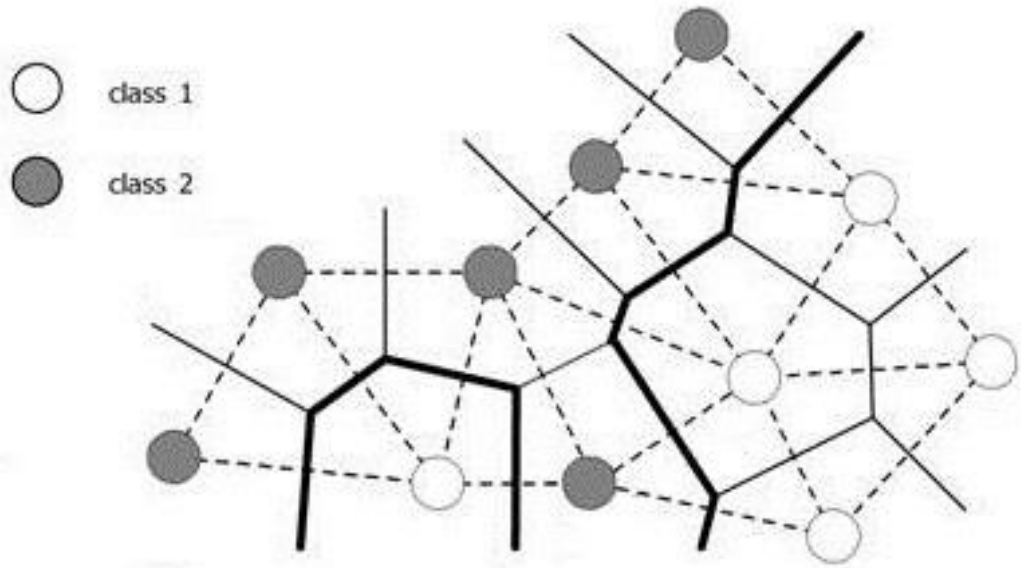

LVQ

Μέθοδοι ανταγωνιστικής μάθησης

http://www.demogng.de